




Nearest-Neighbor Methods
(*Métodos basados en vecinos
cercanos*)

Vecinos más cercanos



K-Nearest Neighbors

Es un algoritmo de aprendizaje supervisado para clasificación y regresión:

- Busca un grupo de k objetos en el conjunto de datos que son **los más cercanos** a la instancia a clasificar.
- Asigna una clase/número basado en la **dominancia de una clase/valor** en particular **en esta vecindad**.
- Basado en **instancias**: en sí, el algoritmo no aprende un modelo. En su lugar, **utiliza los datos de entrenamiento** para predecir nuevos valores.

K-Nearest Neighbors

Puntos clave:

1. El **conjunto de datos** que se usan para evaluar la nueva instancia.
2. Una **métrica de distancia** o similitud para medir la cercanía entre instancias.
3. El valor de k , o el **número de vecinos**.
4. El **método para asignar la clase** a la nueva instancia según la mayoría de los vecinos.

K-Nearest Neighbors

Algoritmo Idea básica de kNN

Entrada : Conjunto de datos D , nuevo punto z , posibles clases L .

Salida : La clase $c_z \in L$ a la que pertenece z .

Para cada $y \in D$:

Calcular la distancia $d(z, y)$

Seleccionar $N \subseteq D$, el conjunto de k puntos más cercanos a z , donde

$$c_z = \operatorname{argmax}_{v \in L} \sum_{y \in N} I(v = \text{clase}(c_y))$$

donde $I(\cdot)$ es la función indicadora.

K-Nearest Neighbors

- En caso de empate:
 - Elegir al azar.
 - Elegir la clase con mayor frecuencia en el conjunto de datos.
- Necesita almacenar todos los puntos, $O(n)$.
- Necesita calcular todas las distancias, $O(n)$.
- No necesita entrenar un modelo, por lo que tarda menos al momento de clasificar.

K-Nearest Neighbors: Distancia

En cuanto a las distancias, se suele usar dos. Para dos puntos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ (ambos vectores de n características):

$$d_{\text{Euclidean}}(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2}$$
$$d_{\text{Manhattan}}(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{k=1}^n |x_k - y_k|}$$

K-Nearest Neighbors: Distancia

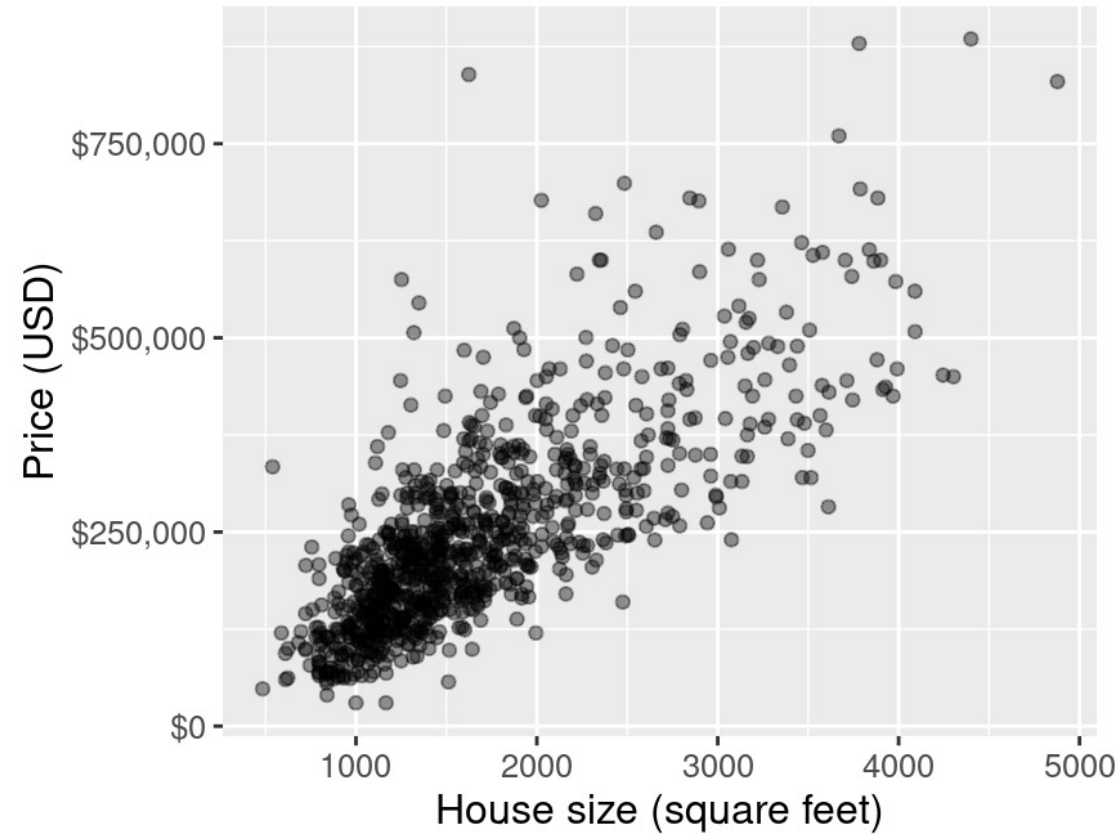
Estas distancias nos permiten implementar el principio «*de entre menor distancia entre dos puntos, mayor es la posibilidad de que ambos sean de la misma clase*».

$$d_{\text{Euclidean}}(x, y) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2}$$
$$d_{\text{Manhattan}}(x, y) = \sqrt{\sum_{k=1}^n |x_k - y_k|}$$

K-Nearest Neighbors: Distancia

- Según la definición de distancia (y como medirla), kNN se puede adaptar a distintos problemas, como clasificación de texto.
- La distancia Euclidiana no es perfecta:
 - Suele ser menos selectiva conforme incrementan el número de características de los puntos.
 - Los valores de las características deben escalarse para evitar que una domine otras.

K-Nearest Neighbors: Regresión



K-Nearest Neighbors: Regresión

Actividad

Leer el siguiente [capítulo](#). Realizar una exposición sobre cómo se aplica kNN para regresión:

- Realizar una presentación con lo más importante.
- Resumir el contenido, digerirlo y explicarlo.
- Tienen 30 minutos.

Tarea

- Investigar sobre el aprendizaje Rote y su uso en el Machine Learning.
- Investigar sobre la similitud coseno, su aplicación en la clasificación de textos y dar un pequeño ejemplo sobre su uso.
- Leer el [siguiente capítulo](#) sobre kNN.
 - Identificar y resumir los principales problemas que sufre kNN en práctica.
 - Identificar y resumir las ventajas de kNN sobre otros modelos de aprendizaje.

Ojo: Buscar fuentes bibliográficas adecuadas para desarrollar su investigación. Cualquier intento de sólo traducir + copiar + pegar, en lugar de **desarrollar el tema de forma adecuada**, hará que **la tarea se considere nula**.



Fin de la presentación de investigación
