

# Regresión Logística

Luis Zúñiga



# Agenda

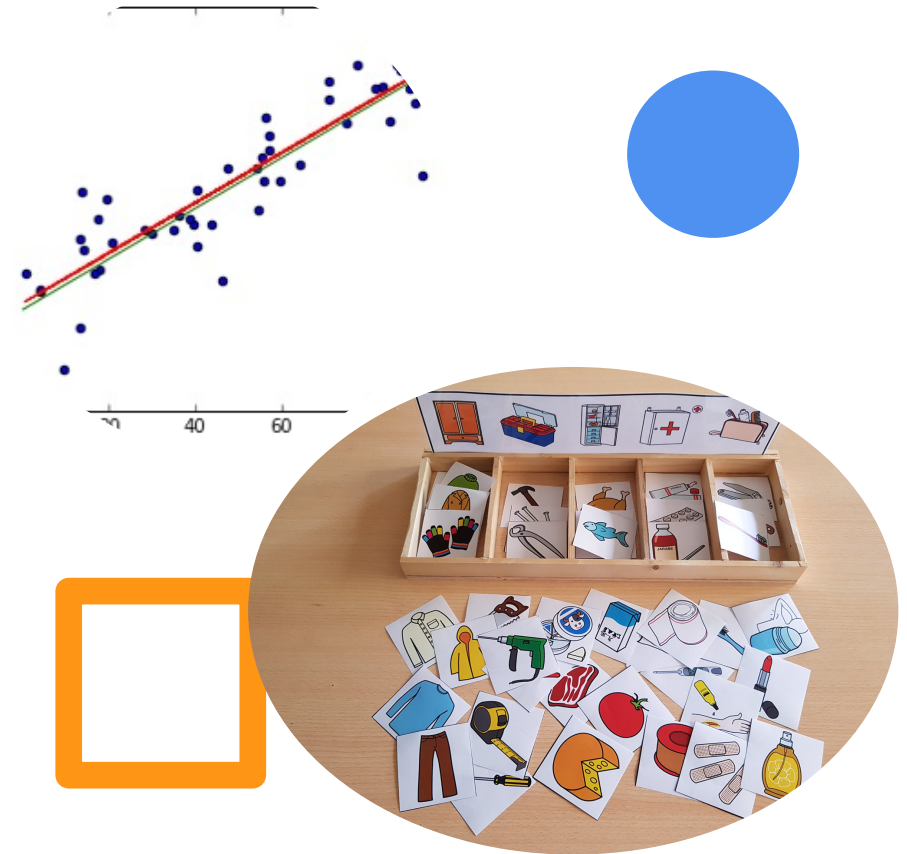
1. Introducción
2. El problema de clasificación
3. Definición de la hipótesis
4. Estimación de parámetros

# Introducción

Los modelos de aprendizaje que vimos anteriormente permiten resolver problemas de **regresión**.

Ahora, vamos a considerar un modelo de **clasificación**: regresión logística.

(¿No les hace ruido el nombre?)



Esta foto de Autor desconocido está bajo licencia [CC BY-SA-NC](#)

# El Problema de Clasificación

El problema de clasificación se reduce a **asignar cada elemento del conjunto de datos a una de dos o más clases**. Por el momento, vamos a facilitar las cosas y **consideraremos únicamente dos clases**. Por ejemplo:

- Email: Spam / No es spam
- Transacciones en línea: Válida / Fraudulenta
- Tumores: Maligno / Benigno

# El Problema de Clasificación

Usualmente, las clases se representan de una manera sencilla mediante valores numéricos:

$$y \in \{0,1\}$$


donde

- 0: clase negativa (e.g., no es spam)
- 1: clase positiva (e.g., es spam)

**Otra vez: vamos a pensar con clasificación binaria.**

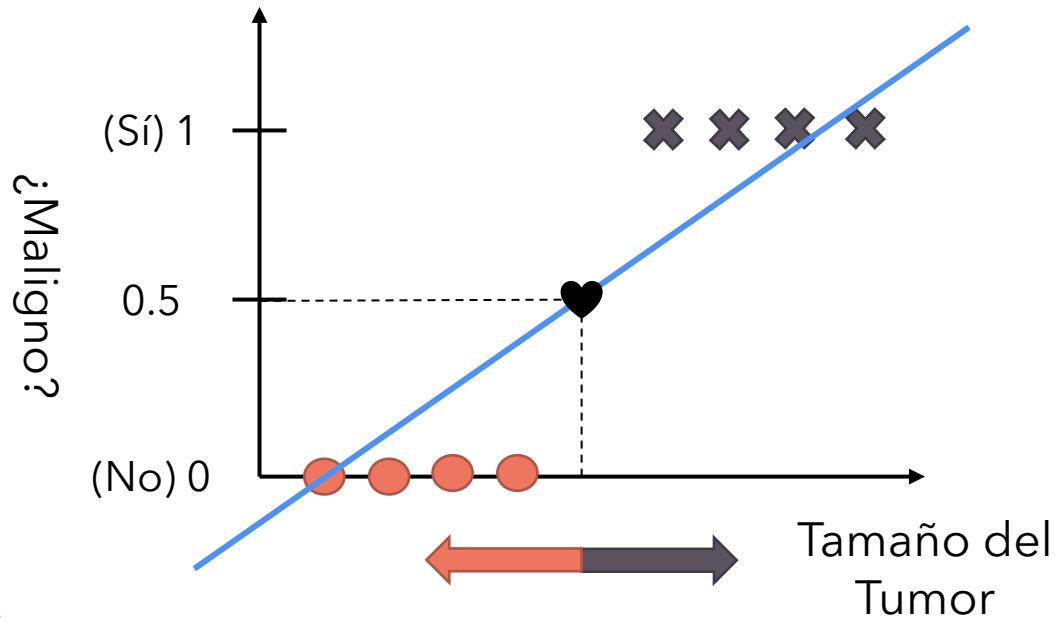
# El Problema de Clasificación

¿Cómo separaría las dos clases?



Vamos a usar esta idea más adelante.

# Primera Idea: Usemos lo que Tenemos




Vamos a utilizar lo que sabemos hasta el momento. Usemos un modelo de regresión lineal simple

$$h_{\theta}(\mathbf{x}) = \Theta^T \mathbf{x}$$

Para separar los puntos, vamos a definir un valor límite de tal manera que:

$$\begin{cases} h_{\theta}(\mathbf{x}) \geq 0.5, y = 1 \\ h_{\theta}(\mathbf{x}) < 0.5, y = 0 \end{cases}$$

# Primera Idea: Usemos lo que Tenemos



Vamos a utilizar lo que sabemos hasta el momento. Usemos un modelo de regresión lineal simple

$$h_{\theta}(\mathbf{x}) = \Theta^T \mathbf{x}$$

Para separar los puntos, vamos a definir un valor límite de tal manera que:

$$\begin{cases} h_{\theta}(\mathbf{x}) \geq 0.5, y = 1 \\ h_{\theta}(\mathbf{x}) < 0.5, y = 0 \end{cases}$$



# Primera Idea: Usemos lo que Tenemos

- En práctica, regresión lineal es un algoritmo que rara vez se adapta a nuestras necesidades.
- Además, al obtener valores en  $\mathbb{R}$ , se puede dar el caso

$$h_{\theta}(x) > 1 \text{ o } h_{\theta}(x) < 0$$

cuando se requiere que

$$y = 0 \text{ o } y = 1$$

# Modelo de Regresión Logística

Se busca que  $0 \leq h_{\theta} \leq 1$ . Con este fin, se propone usar la siguiente función:

$$h_{\theta} = g(\Theta^T \mathbf{x})$$

donde


$$g(z) = \frac{1}{1 + e^{-z}}$$

es decir,

$$h_{\theta} = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

A esta función se le conoce como **función sigmoide** o **función logística**.

¿Cómo se ve? ¡A graficar!



# Modelo de Regresión Logística

¿Cómo un valor en  $\mathbb{R}$  puede determinar un valor en  $y = \{0,1\}$ ?

$h_{\theta}(\mathbf{x})$  = estimación de la probabilidad que  $y = 1$  para el vector de datos  $\mathbf{x}$ .

Por ejemplo, si  $h_{\theta}(\mathbf{x}) = 0.7$ , el paciente tiene un 70% de probabilidad de que el tumor sea maligno.

# Límite de Decisión

¿Cómo se decide qué clase se le asigna a cada dato?

Hipótesis

$$h_{\theta} = g(\theta^T \mathbf{x}) = P(y = 1 | \mathbf{x}; \theta)$$

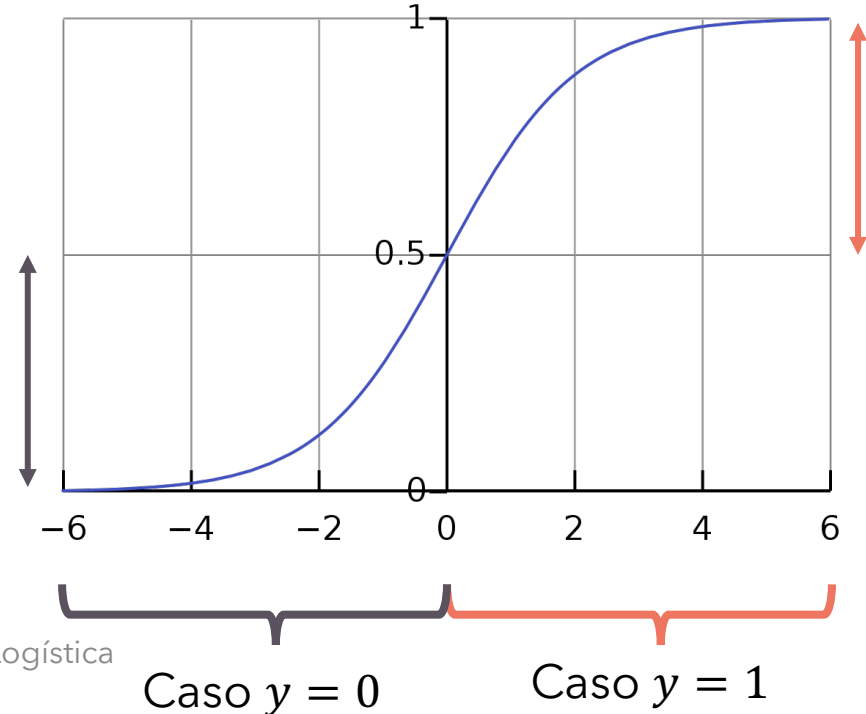
$$g(z) = \frac{1}{1 + e^{-z}}$$

Vamos a establecer la siguiente regla:

$$y = 1 \text{ si } h_{\theta}(\mathbf{x}) \geq 0.5$$

y

$$y = 0 \text{ si } h_{\theta}(\mathbf{x}) < 0.5$$



# Función de Decisión

De nuestro análisis anterior, si

$$y = 1 \text{ si } h_{\theta}(\mathbf{x}) \geq 0.5$$

implica que  $g(z) \geq 0.5$  cuando  $z = \theta^T \mathbf{x} \geq 0$ . De forma similar, si

$$y = 0 \text{ si } h_{\theta}(\mathbf{x}) < 0.5$$

implica que  $g(z) < 0.5$  cuando  $z = \theta^T \mathbf{x} < 0$ .

# Función de Decisión

## Actividad


Supongamos que tenemos la siguiente función:

$$h_{\theta}(\mathbf{x}) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


donde

$$\theta = (-3, 1, 1).$$

¿Cómo se ve la ecuación que determina el caso  $y = 1$  ( $h_{\theta}(\mathbf{x}) \geq 0.5$ )?




# Función de Decisión



¿Qué define nuestra función de separación?

- Este es un ejemplo ideal, rara vez se presenta el caso de la separación lineal.
- Todo depende de la forma de los datos, ya que estos definen los parámetros de la función de decisión.
- Pueden utilizar cualquier función, no solo funciones lineales.

# Función de Decisión



¿Cómo sería la función de decisión en este caso?



# Para recapitular

Se busca que  $0 \leq h_{\theta} \leq 1$ . Con este fin, se propone usar la siguiente función:

$$h_{\theta} = g(\Theta^T \mathbf{x})$$

donde

$$g(z) = \frac{1}{1 + e^{-z}}$$

es decir,

$$h_{\theta} = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

- $z$  nos permite obtener valores entre 0 y 1, similar a una función de probabilidad.
- $z$  puede ser cualquier función, inclusive no lineal.
- $z$  dicta la función que va a separar los puntos de ambas clases.

# Estimación de Parámetros

**Conjunto de Datos:**

$$\{(x_i, y_i)_{i=1}^n\}$$

**Hipótesis:**

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

**$n$  ejemplos**

$$x \in \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad x_0 = 1, \quad y \in \{0, 1\}$$

**Función de Costo**


$$\text{Costo}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{si } y = 0 \end{cases}$$

# Estimación de Parámetros


Recuerden que  $y$  siempre es 0 o 1.

$$\text{cost}(h_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

if  $y = 1$



if  $y = 0$



# Estimación de Parámetros

## Función de Costo

$$\text{Costo}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{si } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{si } y = 0 \end{cases}$$

## Actividad

La función de costo se puede juntar en un sola expresión.  
Encontrar dicha expresión.

La función de costo se puede reducir a **una expresión**:

$$\text{Costo}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

# Estimación de Parámetros

**Hipótesis:**

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

La función de costo se ve (finalmente) de la siguiente manera:

$$J(\boldsymbol{\theta}) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log(h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}))]$$

Aplicando gradiente descendiente:

$$\theta_j = \theta_j - \eta \frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta})$$

donde

$$\frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)}$$

Es decir:

$$\theta_j = \theta_j - \eta \frac{1}{n} \sum_{i=1}^n (h_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)}$$

¡Lo mismo que el modelo de regresión lineal! Solo diferente  $h_{\boldsymbol{\theta}}(\mathbf{x})$ .

# Estimación de Parámetros

**Hipótesis:**

$$h_{\theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

## Tarea



Demostrar que

$$\frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)}$$

donde:




$$J(\boldsymbol{\theta}) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log(h_{\theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(\mathbf{x}^{(i)}))]$$

# Clasificación Multiclase




# Clasificación Multiclase

One-vs-all (one-vs-rest)



Regresión Logística

$$h_{\theta}^{(i)}(\mathbf{x}) = P(y = i | \mathbf{x}; \theta)$$
$$y = \max_i h_{\theta}^{(i)}(\mathbf{x})$$



$h_{\theta}^{(3)}(\mathbf{x})$





# Gracias

Luis Zúñiga

p40887@correo.uia.mx

<https://lzun.github.io>